


بخش اول


قسمت ۱

ابتدا به کمک تابع *unifrnd* دو توزیع S_1 و S_2 را رسم می کنیم. سپس توسط ماتریس A دو توزیع x_1 و x_2 را ایجاد می کنیم. نمودار پراکندگی x_2 بر حسب x_1 در شکل ۱.۱ رسم شده است.



تصویر ۱.۱: نمودار پراکندگی مشاهدات

اگر بررسی کنیم می بینیم که X یک نگاشت از S می باشد که اساس این نگاشت نیز ماتریس A می باشد. اگر نمودار پراکندگی منابع را رسم کنیم به شکل ۱.۲ می رسمیم.



تصویر ۱.۲: نمودار پراکندگی منابع

می بینیم که به دلیل یکنواخت بودن توزیع s_1 و s_2 نمودار پراکندگی منابع مشابه یک مستطیل می باشد که مرز آن دقیقاً مرز توزیع های ما می باشد.

در نتیجه با مقایسه دو تصویر ۱.۱ و ۱.۲ به صورت شهودی می توان به این نتیجه رسید که نگاشت با ماتریس A در شیب و مقیاس منابع اثر می گذارد.

قسمت ۲

طبق روابط به دست آمده در کلاس داریم:

$$X = AS \rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix} s_1 + \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix} s_2 \rightarrow \boxed{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} a_{11}s_1 + a_{12}s_2 \\ a_{21}s_1 + a_{22}s_2 \end{bmatrix}}$$

حال برای بدست آوردن ماتریس A یک سری فرضیات در نظر می گیریم:

- اگر فرض کنیم که در نمودار پراکندگی داده هایی را بررسی می کنیم که x آنها ثابت می باشد (s_1 ثابت) می بینیم که با حرکت در مسیر y (s_2) شیبی برابر با $\frac{a_{21}}{a_{11}}$ داریم.
- اگر فرض کنیم که در نمودار پراکندگی داده هایی را بررسی می کنیم که y آنها ثابت می باشد (s_2 ثابت) می بینیم که با حرکت در مسیر x (s_1) شیبی برابر با $\frac{a_{22}}{a_{12}}$ داریم.

بنابراین با به دست آوردن شیب در نمودار پراکندگی به نسبت ضرایب ماتریس A می رسم. حال می توان یک فرض دیگر در نظر بگیریم تا به تمام درایه های ماتریس دست یابیم:

- فرض می کنیم که اندازه بردار مکانی ها یکه می باشند؛ با داشتن این فرض با داشتن نسبت بین دو درایه بردار مکانی می توان به هر کدام از درایه های بردار مکانی رسید.

بنابراین الگوریتم محاسبه ماتریس A به صورت زیر می باشد:

۱. ابتدا مینیم و ماکزیمم مشاهدات خود را بدست می آوریم. سپس ۴ نقطه یعنی $\{\min(x_1), \min(x_2), \max(x_1), \max(x_2)\}$ را به دست می آوریم سپس می توانیم مقادیر x_1 و x_2 متناظر با آن ها را بدست آوریم. در نتیجه اکنون ۸ نقطه داریم که روی نمودار پراکندگی نمایانگر x, y راس های یک متوازی الاضلاع (شکل ۱.۱) هستند.
 ۲. حال توسط این چهار راس، شیب ۴ ضلع متوازی الاضلاع را بدست می آوریم. در نتیجه $\frac{a_{21}}{a_{11}}, \frac{a_{22}}{a_{12}}$ را داریم. در نتیجه فرض می کنیم که بردار مکانی های ما به در ابتدا به صورت $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ می باشند. حال نسبت ها را در این بردار ها ضرب می کنیم تا به بردار مکانی درست دست یابیم. مشکل این بردار مکانی ها این است که در حال حاضر یکتا نیستند (هر برداری با داشتن این نسبت ضرایب درست است).
 ۳. برای اینکه بردار های مکانی ما یکتا شوند آنها را یکبار فرض می کنیم. در نتیجه آنها را بر نرم خود تقسیم می کنیم. در نتیجه اکنون به بردار های مکانی یکبار و یکتا رسیدیم.
- نتیجه یک بار اجرا توسط این الگوریتم در زیر آمده است:


$$A \approx \begin{bmatrix} 0.5986 & 0.8011 \\ 0.8154 & -0.5788 \end{bmatrix}$$

ممکن بود که ماتریس A دارای ابهام جایگشت نیز باشد. که در اینجا به علت همسان بودن درایه های ماتریس با الگوریتمی که من پیاده سازی کردم این ابهام وجود ندارد (اگر درایه های سطر اول ماتریس مثبت نبودند با الگوریتمی که من پیاده سازی کردم یک مثبت و منفی جابجا می شد).

این الگوریتم، بدیهی ترین الگوریتم موجود می باشد. حال، با کمی تغییر سعی در بهبود الگوریتم داریم. الگوریتم بهبود یافته به صورت زیر می باشد:

۱. ابتدا مینیم و ماکزیمم مشاهدات خود را بدست می آوریم. سپس ۴ نقطه یعنی $\{\min(x_1), \min(x_2), \max(x_1), \max(x_2)\}$ را به دست می آوریم سپس می توانیم مقادیر x_1 و x_2 متناظر با آن ها را بدست آوریم. در نتیجه اکنون ۸ نقطه داریم که روی نمودار پراکندگی نمایانگر x, y راس های یک متوازی الاضلاع (شکل ۱.۱) هستند. (این گام کاملاً مشابه گام ۱ الگوریتم قبلی می باشد).
۲. حال با دستور *linspace* این ۴ ضلع متوازی الاضلاع را رسم می کنیم. تعداد نقاط این اضلاع هم توسط یک متغیر تعیین می کنیم که قابل تغییر باشد.
۳. در این گام، فاصله تمام نقاط روی خط را با تمام ۱۰۰۰ نقطه مشاهدات خود می سنجیم و به ازای هر نقطه روی خط کمترین فاصله و اندیس آن را بدست می آوریم.
۴. بدیهی است که ممکن است این اندیس ها به ازای هر نقطه روی خط تکراری نیز باشند، در نتیجه با استفاده از دستور *unique()* اندیس های غیر تکراری را جداسازی می کنیم.
۵. در این گام با اندیس های باقیمانده و مشاهدات، شیب ۴ خط جدید را با استفاده از دستور *polyfit()* بدست می آوریم. (ادامه کار کاملاً مشابه گام های ۲ و ۳ الگوریتم قبلی می باشد).

شکل نمودار پراکندگی + این چهار خط متوازی الاضلاع در تصویر ۱.۳ آورده شده است.



تصویر ۱.۳: نمودار پراکندگی مشاهدات + ضلع های متوازی الاضلاع مینیمم و ماکسیمم ها

همچنین، نتیجه یک بار اجرا توسط این الگوریتم در زیر نشان داده شده است:

$$A \approx \begin{bmatrix} 0.6004 & 0.7997 \\ 0.8086 & -0.5883 \end{bmatrix}$$

قسمت ۳


برای این قسمت با دستور `awgn()` یک نویز سفید گوسی به مشاهدات خود اضافه می کنیم به نحوی که SNR ما برابر با ۱۵ دسی بل باشد. حال هر دو الگوریتم را اجرا می کنیم.

الگوریتم اول: نتیجه یک بار اجرا توسط این الگوریتم در زیر آمده است:

$$A \approx \begin{bmatrix} 0.5784 & 0.8158 \\ 0.7839 & -0.6209 \end{bmatrix}$$

می بینیم که این الگوریتم عملکرد نه چندان خوبی در برابر نویز دارد. حال الگوریتم دوم را بررسی می کنیم.

الگوریتم دوم: شکل نمودار پراکندگی + نویز + این چهار خط متوازی الاضلاع در تصویر ۱.۴ آورده شده است.



تصویر ۱.۴: نمودار پراکندگی مشاهدات + نویز + ضلع‌های متوازی‌الاضلاع مینیمم و ماکسیمم‌ها

همچنین، نتیجه یک بار اجرا توسط این الگوریتم در زیر نشان داده شده است:


$$A \approx \begin{bmatrix} 0.5909 & 0.8068 \\ 0.8086 & -0.6120 \end{bmatrix}$$

می‌بینیم که این الگوریتم عملکرد بسیار بهتری در برابر نویز نسبت به الگوریتم اول دارد. همچنین با تقریب خوبی می‌توان گفت که این الگوریتم در برابر نویز مقاوم است (هر درایه حدود ۰.۱ با مقدار واقعی خود تفاوت دارد).

همچنین، میتوان با چند بار اجرا کردن این الگوریتم، به مقادیر دقیق‌تری رسید.

قسمت ۴

نمودار هیستوگرام x_1 در تصویر ۱.۵ نشان داده شده است.

تصویر ۱.۵: هیستوگرام x_1

حال، روابط ریاضی آن را می‌نویسیم:

$$A = \begin{bmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{bmatrix} \rightarrow A^{-1} = \frac{1}{-1} \begin{bmatrix} -0.6 & -0.8 \\ -0.8 & 0.6 \end{bmatrix} = \begin{bmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{bmatrix}$$


$$X = AS \rightarrow S = A^{-1}X \rightarrow \begin{cases} s_1 = 0.6x_1 + 0.8x_2 \\ s_2 = 0.8x_1 - 0.6x_2 \end{cases}$$

طبق توزیع های s_1 و s_2 می‌دانیم که $-3 \leq s_1 \leq 3$ و $-2 \leq s_2 \leq 2$ بنابراین جایگزین می‌کنیم:

$$\begin{cases} -3 \leq 0.6x_1 + 0.8x_2 \leq 3 \\ -2 \leq 0.8x_1 - 0.6x_2 \leq 2 \end{cases} \Rightarrow \begin{cases} 0.8^{-1}(-3 - 0.6x_1) \leq x_2 \leq 0.8^{-1}(3 - 0.6x_1) \\ 0.6^{-1}(-2 + 0.8x_1) \leq x_2 \leq 0.6^{-1}(2 + 0.8x_1) \end{cases}$$

$$\rightarrow \boxed{\begin{cases} -3.75 - 0.75x_1 \leq x_2 \leq 3.75 - 0.75x_1 \\ -3.33 + 1.33x_1 \leq x_2 \leq 3.33 + 1.33x_1 \end{cases}}$$

نمودار پراکندگی بدست آمده توسط روابط ریاضی در تصویر ۱.۶ رسم شده است.



تصویر ۱.۶: نمودار پراکتدگی بدست آمده توسط روابط ریاضی

حال از روی تصویر ۱.۶ و از روابطی که به دست آوردیم تابع توزیع حاشیه ای x_1 را به دست می آوریم:

$$f(s_1, s_2) \xrightarrow{\text{استقلال}} f(s_1)f(s_2) = \frac{1}{2 - (-2)} \times \frac{1}{3 - (-3)} = \frac{1}{4} \times \frac{1}{6} = \frac{1}{24}$$

$$J = \begin{vmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{vmatrix} = -1 \Rightarrow |J| = 1$$


$$f_{X_1, X_2}(x_1, x_2) = \frac{f_{S_1, S_2}(s_1, s_2)}{|J|} = \frac{1}{24}$$

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$$

$$\rightarrow f_{X_1}(x_1) = \begin{cases} \int_{-3.33+1.33x_1}^{3.75-0.75x_1} \frac{1}{24} dx_2 = \frac{1}{24} (7.08 - 2.08x_1) & 0.202 < x_1 < 3.404 \\ \int_{-3.33+1.33x_1}^{3.33+1.33x_1} \frac{1}{24} dx_2 = \frac{1}{24} (6.66) = 0.2775 & -0.202 < x_1 < 0.202 \\ \int_{3.75-0.75x_1}^{3.33+1.33x_1} \frac{1}{24} dx_2 = \frac{1}{24} (7.08 + 2.08x_1) & -3.404 < x_1 < -0.202 \end{cases}$$

می دانیم که بازه هایی که برای x_1 نوشته شده حدودی و از روی تصویر ۱.۶ می باشد. در اصل، مقدار اصلی این محدوده ها به صورت $\{-3.4, -0.2, 0.2, 3.4\}$ می باشند.


نمودار توزیع حاشیه ای x_1 در تصویر ۱.۷ نشان داده شده است.

تصویر ۱.۷: تابع توزیع حاشیه ای x_1

با مقایسه دو تصویر ۱.۵ و ۱.۷ می بینیم که نمودار هیستوگرام x_1 با تابع توزیع حاشیه ای x_1 تقریباً یکسان می باشند. علت تفاوت این دو تصور به علت کم بودن نسبی مشاهدات ما می باشد (تعداد مشاهدات ما از x_1 برابر با ۱۰۰۰ می باشد).

قسمت ۵

نمودار هیستوگرام x_2 در تصویر ۱.۸ آمده است.

تصویر ۱.۸: هیستوگرام x_2

حال، روابط ریاضی آن را می نویسیم:

$$A = \begin{bmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{bmatrix} \rightarrow A^{-1} = \frac{1}{-1} \begin{bmatrix} -0.6 & -0.8 \\ -0.8 & 0.6 \end{bmatrix} = \begin{bmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{bmatrix}$$

$$X = AS \rightarrow S = A^{-1}X \rightarrow \begin{cases} s_1 = 0.6x_1 + 0.8x_2 \\ s_2 = 0.8x_1 - 0.6x_2 \end{cases}$$

طبق توزیع های s_1 و s_2 می دانیم که $-3 \leq s_1 \leq 3$ و $-2 \leq s_2 \leq 2$ بنابراین جایگزین می کنیم:

$$\begin{cases} -3 \leq 0.6x_1 + 0.8x_2 \leq 3 \\ -2 \leq 0.8x_1 - 0.6x_2 \leq 2 \end{cases} \Rightarrow \begin{cases} 0.6^{-1}(-3 - 0.8x_2) \leq x_1 \leq 0.6^{-1}(3 - 0.8x_2) \\ 0.8^{-1}(-2 + 0.6x_2) \leq x_1 \leq 0.8^{-1}(2 + 0.6x_2) \end{cases}$$

$$\rightarrow \boxed{\begin{cases} 5 - 1.33x_2 \leq x_1 \leq 5 - 1.33x_2 \\ -2.5 + 0.75x_2 \leq x_1 \leq 2.5 + 0.75x_2 \end{cases}}$$

نمودار پراکندگی مشابه تصویر ۱.۶ می باشد.


حال از روی تصویر ۱.۶ و از روابطی که به دست آوردیم تابع توزیع حاشیه ای x_2 را به دست می آوریم:

$$f_{X_2}(x_2) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_1$$

$$\rightarrow f_{X_2}(x_2) = \begin{cases} \int_{-2.5+0.75x_2}^{5-1.33x_2} \frac{1}{24} dx_1 = \frac{1}{24}(7.5 - 2.08x_1) & 1.197 < x_2 < 3.599 \\ \int_{-2.5+0.75x_2}^{2.5+0.75x_2} \frac{1}{24} dx_1 = \frac{1}{24}(5) = 0.2083 & -1.197 < x_2 < 1.197 \\ \int_{-5-1.33x_2}^{2.5+0.75x_2} \frac{1}{24} dx_1 = \frac{1}{24}(7.05 + 2.08x_1) & -3.599 < x_2 < -1.197 \end{cases}$$

می دانیم که بازه هایی که برای x_2 نوشته شده حدودی و از روی تصویر ۱.۶ می باشد. در اصل، مقدار اصلی این محدوده ها به صورت $\{-3.6, -1.2, 1.2, 3.6\}$ می باشند.

نمودار توزیع حاشیه ای x_2 در تصویر ۱.۹ نشان داده شده است.



تصویر ۱.۹: تابع توزیع حاشیه ای x_2

با مقایسه دو تصویر ۱.۸ و ۱.۹ می بینیم که نمودار هیستوگرام x_2 با تابع توزیع حاشیه ای x_2 تقریباً یکسان می باشند. علت تفاوت این دو تصور به علت کم بودن نسبی مشاهدات ما می باشد (تعداد مشاهدات ما از x_2 برابر با ۱۰۰۰ می باشد).

قسمت ۶

به صورت یکتا خیر؛ همان طور که در قسمت قبل دیدیم به طور شهودی می توان از روی هیستوگرام ها مسئله BSS را حل کرد. به طور نظری نیز می توان گفت:

$$F_{X_1}(x_1) = \Pr\{X_1 < x_1\} = \Pr\{a_{11}s_1 + a_{12}s_2 < x_1\} \rightarrow \begin{cases} a_{11}s_1 = s_3 \\ a_{12}s_2 = s_4 \end{cases} \\ \rightarrow \int_{-\infty}^{\infty} \int_{-\infty}^{x_1-s_3} f_{s_3,s_4}(s_3, s_4) ds_3 ds_4 \xrightarrow{\text{استقلال}} \int_{-\infty}^{\infty} f_{s_4}(s_4) \int_{-\infty}^{x_1-s_3} f_{s_3}(s_3) ds_3 ds_4$$

می بینیم که قسمتی از عبارت به شکل کانولوشن شد. در نهایت داریم:

$$\boxed{F_{X_1}(x_1) = f_{s_4}(x_1) * f_{s_3}(x_1)}$$

بنابراین این نگاشت را به صورت یک کانولوشن فرض می کنیم. برای x_2 نیز به صورت مشابه داریم:

$$F_{X_2}(x_2) = \Pr\{X_2 < x_2\} = \Pr\{a_{21}s_1 + a_{22}s_2 < x_2\} \rightarrow \begin{cases} a_{21}s_1 = s_3 \\ a_{22}s_2 = s_4 \end{cases} \\ \rightarrow \int_{-\infty}^{\infty} \int_{-\infty}^{x_2-s_3} f_{s_3,s_4}(s_3, s_4) ds_3 ds_4 \xrightarrow{\text{استقلال}} \int_{-\infty}^{\infty} f_{s_4}(s_4) \int_{-\infty}^{x_2-s_3} f_{s_3}(s_3) ds_3 ds_4$$

می بینیم که قسمتی از عبارت به شکل کانولوشن شد. در نهایت داریم:


$$\boxed{F_{X_2}(x_2) = f_{s_4}(x_2) * f_{s_3}(x_2)}$$

حال چون نحوه عملکرد کانولوشن را می دانیم می توانیم از نقاط شکست توابع توزیع اطلاعاتی درباره منابع خود به دست آوریم، اما هنوز ابهام جایگشت وجود دارد و ممکن است که علامت درایه های ماتریس A درست به دست نیایند.

بخش دوم

قسمت ۱


تابع سه بعدی مش به صورت خطی و به صورت لگاریتمی در تصویر ۲.۱ رسم شده است.



تصویر ۲.۱: تابع مش به صورت خطی و لگاریتمی

قسمت ۲

سطوح هم پتانسیل به صورت خطی و به صورت لگاریتمی در تصویر ۲.۲ رسم شده اند.



تصویر ۲.۲: سطوح هم پتانسیل به صورت خطی و لگاریتمی

قسمت ۳

طبق روابط بدست آمده در کلاس داریم:

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 2x_1 + x_2 - 4 \\ x_1 + 2x_2 - 6 \end{bmatrix}, \quad H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

برای اثبات $convex$ بودن تابع هدف نیز داریم:

$$x^T H x > 0 \rightarrow \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} > 0 \rightarrow 2(x_1^2 + x_1 x_2 + x_2^2) > 0$$

$$\Rightarrow x_1^2 + x_1 x_2 + x_2^2 > 0 \xrightarrow{\Delta = x_2^2 - 4x_1 x_2 + 3x_1^2} \Delta < 0 \rightarrow \text{بدون ریشه}$$

در نتیجه تابع هدف ما $convex$ می باشد.

قسمت ۴

طبق روابطی که در قسمت ۲ بدست آوردیم داریم:

$$\nabla f = \begin{bmatrix} 2x_1 + x_2 - 4 \\ x_1 + 2x_2 - 6 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{cases} x_1 = \frac{2}{3} \\ x_2 = \frac{8}{3} \end{cases} \Rightarrow x = \begin{bmatrix} \frac{2}{3} \\ \frac{8}{3} \end{bmatrix}$$


قسمت ۵

ابتدا $\mu = 0.1$ را قرار می دهیم و مشاهده می شود برای اینکه خطای بین تابع هدف در دو $iteration$ کمتر از 10^{-6}

شود باید $59 iteration$ انجام شود و مقادیر نهایی x برابر با $x = \begin{bmatrix} 0.6687 \\ 2.6647 \end{bmatrix}$ می باشد.

برای $\mu = 0.01$ باید $494 iteration$ انجام شود و مقادیر نهایی x برابر با $x = \begin{bmatrix} 0.6736 \\ 2.6597 \end{bmatrix}$ می باشد.

نمودار همگرایی در تصویر ۲.۳ رسم شده است.

تصویر ۲.۳: الگوریتم $S.D$ با دو μ متفاوت

قسمت ۶


در این روش چون تابع هدف ما درجه ۲ می باشد در 1 iteration به مقدار مینیمم هدف می رسیدیم، و مقادیر x دقیقاً همان مقادیر مینیمم می باشند. دلیل این اتفاق این است که حداکثر درجه تابع هدف ما برابر با ۲ می باشد.

قسمت ۷

در این روش یک بار x_1 را ثابت فرض می کنیم و تابع هدف را نسبت به x_2 مینیمم می کنیم. بار دیگر x_2 را ثابت فرض می کنیم و تابع هدف را نسبت به x_1 مینیمم می کنیم. این روش در 14 iteration به مقدار هدف می رسد و مقادیر نهایی

$$x = \begin{bmatrix} 0.6663 \\ 2.6669 \end{bmatrix} \text{ می باشد.}$$

تصویر سطوح هم پتانسیل + خطوط این روش در تصویر ۲.۴ آمده است.



تصویر ۲.۴: سطوح هم پتانسیل به صورت لگاریتمی + خطوط *Alternation Minimization*

قسمت ۸

این روش مشابه روش قسمت ۵ می باشد با این تفاوت که هر بار بعد از تغییر x باید قید یکه بودن را به آن اعمال کنیم.

بنابراین $\mu = 0.1$ را قرار می دهیم و مشاهده می شود برای اینکه خطای بین تابع هدف در دو *iteration* کمتر از

10^{-6} شود باید *15 iteration* انجام شود و مقادیر نهایی x برابر با $x = \begin{bmatrix} 0.4946 \\ 0.8691 \end{bmatrix}$ می باشد.

قسمت ۹

برای روش لاگرانژ داریم:

$$\begin{cases} f = x_1^2 + x_2^2 - 4x_1 - 6x_2 + x_1x_2 + 13 \\ x_1^2 + x_2^2 = 1 \end{cases}$$

$$\nabla f = \gamma \nabla g \Rightarrow \begin{cases} 2x_1 - 4 + x_2 = \gamma(2x_1) \\ 2x_2 - 6 + x_1 = \gamma(2x_2) \end{cases}$$

فرض می کنیم که x_1 و x_2 صفر نمی باشند. حال داریم:

$$\begin{cases} 1 - \frac{2}{x_1} + \frac{x_2}{2x_1} = \gamma \\ 1 - \frac{3}{x_2} + \frac{x_1}{2x_2} = \gamma \end{cases} \rightarrow \frac{2}{x_1} - \frac{x_2}{2x_1} = \frac{3}{x_2} - \frac{x_1}{2x_2} \rightarrow \begin{cases} x_1 = 0.494, x_2 = 0.869 \rightarrow f = 7.237 \\ x_1 = -0.589, x_2 = -0.807 \rightarrow f = 21.68 \\ x_1 = 3.047 \pm j1.893 \text{ غیر قابل قبول} \end{cases}$$

بنابراین نقطه بهینه همان $x_1 = 0.494, x_2 = 0.869$ می باشد که با مقدار قسمت ۸ تقریباً یکی است.